台灣消防法規 RAG 前端操作說明書

Streamlit 本機問答介面使用指南

文件版本 2.5
更新日期 2026-10-16

本手冊說明本機 Streamlit
前端的安裝啟動、日常查詢、對話管理、證據查核與常見問題。

1 文件用途與適用範圍

本說明書供使用 Streamlit 前端查詢台灣消防法規的一般使用者與業務人員使用。內容包含啟動、介面辨識、對話管理、檢索設定、提問、法源查核與常見問題。系統預設在 Windows 10/11 本機執行，不需要 Docker、WSL 或 PostgreSQL。

前端用於查詢與閱讀現行版本法規證據。回答是輔助檢索結果，實際法律判斷仍應以主管機關公告、原始法規與正式解釋為準。

2 使用前準備

啟動前請確認下列項目。

- 已安裝 Python 3.11 以上版本。
- 專案根目錄已建立 .venv 並安裝 ui 選配依賴。
- 已建立 .env，且已執行資料庫初始化。
- data/nfa_fire_law.db 已有法規資料；若尚無資料，應由管理者先完成小量 probe 與增量爬取。

首次安裝可在 PowerShell 執行：

```
python -m venv .venv
Copy-Item .env.example .env
.venv\Scripts\python.exe -m pip install -e ".[ui]"
.venv\Scripts\python.exe -m app.cli init-db
```

3 啟動與停止

3.1 雙擊啟動

在檔案總管中雙擊 scripts\start_streamlit.bat。啟動器會檢查專案的 .venv 與 Streamlit，啟動後自動開啟 http://127.0.0.1:8501。若 8501 已由本專案先前啟動的 Streamlit
占用，啟動器會安全重啟該程序；其他應用程式占用時則不會任意終止。啟動器不會自動安裝套件，也不會爬取法規。

3.2 PowerShell 啟動

```
.venv\Scripts\python.exe -m streamlit run app/streamlit_app.py `
  --server.address 127.0.0.1 `
  --server.port 8501 `
  --browser.gatherUsageStats false
```

頁面上方顯示「台灣消防法規 RAG」後即可開始使用。如果啟動後沒有自動開啟瀏覽器，可手動輸入上述網址。

3.3 停止服務

若以 PowerShell 啟動，回到執行視窗按 Ctrl+C。若以批次檔啟動，關閉對應的 Streamlit 視窗即可。不要為了釋放 8501 連接埠而任意終止其他程式。

4 介面總覽

介面分為左側功能區與右側問答區。左側包含對話列表與檢索設定；右側顯示目前對話、回答、引用與法規證據。



圖 1 前端首頁、對話列表、檢索設定與成功回答區

5 對話管理

- 按「＋新增對話」可建立空白對話。
- 按左側對話標題可切換紀錄，目前對話前會顯示指示符號。
- 按對話右側的「⋯」可編輯標題或刪除對話。
- 對話紀錄保存在本機 SQLite，重新啟動後仍可繼續。

刪除對話會移除該對話及其訊息。若需留存紀錄，請在刪除前確認。

6 檢索設定



圖 2 左側對話列表與檢索設定

設定	作用	使用建議
顯示結果數	設定一般查詢顯示的本機 RAG 證據數，範圍 1 至 20；Web 補充不計入此數量。完整列舉問題可能依章節自動超過此數量	首次使用為 8；調整後立即存到本機 SQLite，重新啟動會恢復最後設定。複雜比較可適度增加
法規篩選	限定只在指定法規中檢索	已知法規名稱時使用；跨法規問題保留「全部法規」
gemma4:e2b	本機速度優先；預設 8,192/2,048 tokens（context/output）	快速查找與較短回答
gemma4:e4b	本機品質優先；預設 16,384/4,096 tokens（context/output）	較完整的整理
gemma4:31b-cloud	雲端品質優先；預設 262,144/8,192 tokens（context/output）	需要 OLLAMA_API_KEY

左側下方會顯示儲存 backend、embedding provider 與向量維度。這些是系統狀態資訊，一般使用者不需要調整。

7 提問與回答

7.1 建議提問方式

在頁面底部的輸入框輸入自然語言問題，再送出查詢。提問時建議同時提供法規名稱、條號、角色或行為，例如：

- 消防法第13條對管理權人有什麼要求？
- 消防設備師與消防設備士的業務範圍有何不同？
- 只查找消防法，說明管理權人的定義。
- /web 消防法第13條最新修正內容

問題開頭的 /web 會強制嘗試官方網頁搜尋，即使本機法規已有高分結果或已完整取回某章節。系統會先移除指令再檢索、搜尋和回答；對話紀錄仍顯示原始提問。只有開頭且獨立的 /web 才是指令，單獨輸入 /web 會提示補上問題。

例如 /web 一定規模以上之建築物的中央主管機關公告? 會搜尋內政部等允許清單中的官方網站。顯示「沒有找到允許清單內的官方來源」代表已嘗試搜尋，但結果未通過來源或相關性篩選；若管理者自訂搜尋網域，應確認包含 moi.gov.tw。

即使未輸入 /web，明確詢問主管機關、內政部或消防署的「公告」時，系統也會自動嘗試官方網頁搜尋。一般法條問題仍依本機檢索結果判斷是否需要補充 Web
資料。自動搜尋的畫面提示會說明是否取得官方來源，不代表本機檢索一定不足。

系統在處理期間會顯示「正在檢索法規並整理回答」。請等待完成，不要連續重複送出相同問題。

啟動頁面、重新整理、送出問題完成回答，或從左側切換既有對話時，畫面會停留在該對話最後一輪的「問題」起點，再往下閱讀回答；不會自動捲到對話最底部。尚未提問的空白對話則維持目前頁面位置。

7.2 閱讀回答與引用

回答中的 [1]、[2] 等編號是可點選引用。按編號後會移到對應的證據卡並展開內容。每張本機證據卡顯示：

- 法規名稱、條號或標籤、章節與版本。
- hybrid、vector 與 lexical 檢索分數。
- 作為回答依據的法規原文。

- 「開啟原始來源」連結。

本機證據卡預設嚴格依 [1] 至 [N]
的引用編號順序顯示，即使同一法規出現多筆，也不會集中卡片而造成跳號；「顯示結果數」計算條文筆數。若另有 Web 補充，會接續編號，例如本機有 8 筆時，Web 證據從 [9] 開始。介面會另外顯示本機與 Web
的編號範圍。回答只需引用實際支持主張的證據，不一定會引用畫面上的每一張卡片。

回答顯示時，所有證據卡（包含第 1
筆）預設收合。點選回答中的引用編號會跳到並展開對應卡片；也可以點選卡片標題自行展開或收合。

當問題明確要求單一法規的「所有 / 全部 / 完整 / 逐條」懲處或罰則條文時，系統會改用結構式章節檢索，不以一般結果數截斷。畫面會顯示「完整列舉模式」、法規 / 章節與覆蓋數，例如 21 / 21；證據卡顯示「結構式章節檢索 · 依條文順序」，不顯示虛構的 hybrid 分數。只有 returned_matches 等於 total_matches 時，系統才標示完整。

對複合包含問題，直接涵蓋明確對象的條文優先，相關母法其次。卡片保留原始 hybrid、vector 與 lexical
分數；分數代表檢索相關度，不代表法律位階。

回答下方的診斷列顯示模型、實際輸出 token 數、有效輸出上限、中文生成狀態及重試次數。正常結束會顯示「生成狀態：已完成」，不直接呈現容易誤解的技術終止碼 stop；有效上限會依剩餘 context
縮小。若回答因長度中斷，系統會精簡重試一次，仍未完成時顯示「達到輸出上限，回答未完整」並明確警告。



圖 3 回答與預設收合的法規證據卡

7.3 官方網頁補充資料

當本機 RAG 沒有結果或最高分數低於設定門檻，且系統已設定 OLLAMA_API_KEY 時，系統可嘗試補充允許清單內的 HTTPS 官方網頁。若在問題開頭輸入 /web
，當次會強制嘗試搜尋，不受本機檢索分數影響。系統會先排除未包含問題明確查詢對象的 Web
結果，再將保留來源接續本機證據編號。介面會標示 Web 筆數、擷取時間與連結。若未設定 key、連線失敗、系統停用或沒有相關來源，介面會說明實際狀態，本機檢索結果仍會保留；強制搜尋不保證取得可引用的網頁資料。

查找主管機關公告或最新版法規時，系統會以正式公告名稱或全國法規資料庫現行全文追加一次精確搜尋，去除重複網址後，只保留設定上限內的 HTTPS 官方來源。有官方頁面明示的發布、發文、公告或修正日期時，證據卡會把「來源日期」與「擷取時間」分開顯示，較新的來源排前面。生效日期不等同發布日期；即使卡片排出較新來源，有限的搜尋結果仍不能證明沒有更新版本，請開啟官方原始頁面與沿革核對。

8 查核回答的建議流程

1. 先閱讀回答並確認是否直接回應問題。
2. 按回答中的引用編號，核對對應條文。
3. 確認法規名稱、條號、版本與條文內容符合問題。
4. 如果涉及正式法律判斷，按「開啟原始來源」進一步查證。
5. 證據不足時，加入法規名稱、條號或更明確的行為後重新提問。

9 常見問題與排除

現象	處理方式
瀏覽器無法開啟頁面	確認 Streamlit 視窗仍在執行，再開啟 http://127.0.0.1:8501；若啟動器顯示 8501 被其他程序占用，保留 PID 與錯誤訊息供管理者辨識
顯示端口被佔用	新版啟動器可辨識本專案 Windows venv 的父子程序鏈並安全重啟；若仍拒絕啟動，表示有限父鏈內無法確認是本專案程序，請勿直接終止不相干程式
無法載入法規清單	由管理者確認 .env、DATABASE_URL 與資料庫初始化狀態
檢索沒有結果	改用法規正式名稱、條號或具體關鍵詞；必要時移除過度限定的法規篩選
顯示 LLM 錯誤	法規證據仍可閱讀；請管理者檢查 Ollama 連線、模型名稱、key 與 timeout
顯示回答未完整	查看診斷列的生成狀態、實際輸出 / 上限與重試次數；可縮小問題範圍或減少顯示結果數後重問
web fallback 不可用	確認是否已設定 OLLAMA_API_KEY 與允許的官方網域；本機證據仍可使用
對話標題或紀錄不如預期	重新整理頁面；如果持續發生，請保留錯誤畫面與時間交由管理者檢查

10 使用與資安邊界

- 介面只綁定 127.0.0.1，適合本機使用，未提供登入驗證。
- 不要將介面直接暴露到公開網路或區域網路。
- .env、API key、下載附件與本機資料庫不得加入 Git。
- 不建議在問題中輸入不必要的個人資料、機密或認證資訊。

11 文件維護與版本對齊

本 Markdown 是前端操作說明書的文字來源，docs/assets/frontend-user-guide/ 是畫面來源。前端功能、可見文字、使用流程、預設選項、回答狀態、引用或啟動方式異動時，必須在同一次變更中完成：

1. 更新 docs/FRONTEND_USER_GUIDE.md 的受影響章節。
2. 重新擷取受影響畫面，不沿用已過時截圖。
3. 執行 scripts/build_frontend_user_guide.py --format all，同步產生 Word 與 PDF。
4. 逐頁檢查 Word 轉圖與 PDF 轉圖，確認繁體中文、表格、程式碼、截圖和頁碼清楚易讀。
5. 將 Markdown、截圖、產生器、Word 與 PDF 一併納入同一次 commit。

僅有內部重構且不影響可見行為時，可不重新擷取截圖。實際文件對齊與交付檢查仍以 repository 根目錄 AGENTS.md 第 17 節為準。

11.1 更新紀錄

日期	版本	異動說明
2026-10-16	2.5	公告與最新版法規精確搜尋，證據卡分別顯示來源日期與擷取時間
2026-10-15	2.4	明確詢問主管機關公告時自動嘗試官方網頁搜尋，修正自動搜尋提示
2026-10-15	2.3	問題開頭的 /web 可強制搜尋；預設納入內政部公告網域，並說明無結果狀態
2026-10-13	2.1	顯示結果數調整後立即保存，重新啟動恢復最後設定
2026-09-29	2.0	證據卡改為預設收合，點選回答引用時才展開對應資料
2026-09-24	1.9	修正 Windows venv 監聽子程序被誤判為外部程序，導致重複雙擊無法開啟頁面
2026-09-24	1.8	完整列舉問題改用結構式章節檢索，顯示章節範圍與證據覆蓋數
2026-09-22	1.7	問答載入、送出回答及切換對話時，視窗定位到最新問題起點
2026-09-17	1.6	證據卡改為依引用編號順序顯示，避免依法規分組造成跳號
2026-09-16	1.5	診斷列加入實際輸出 token 數，並將技術終止碼改為易懂的中文生成狀態
2026-09-16	1.4	加入模型別 token 上限、截斷重試/警告、證據依法規分組及跨法規來源多樣化說明
2026-09-16	1.3	說明直接條文、母法的證據順序及原始分數意義
2026-09-15	1.2	明確區分本機與 Web 證據數，統一 [N] 編號與排列順序，加入 Web 相關性說明並更新回答證據截圖
2026-09-15	1.1	重新擷取成功回答案例，取代已刪除的失敗案例截圖，並同步更新 Word 與 PDF
2026-09-15	1.0	建立前端專用操作說明書，納入實際畫面、Word、PDF 與後續對齊規範