台灣消防法規 RAG 前端操作說明書

Streamlit 本機問答介面使用指南

文件版本 2.2
更新日期 2026-10-15

本手冊說明本機 Streamlit
前端的安裝啟動、日常查詢、對話管理、證據查核與常見問題。

1 文件用途與適用範圍

本說明書供使用 Streamlit 前端查詢台灣消防法規的一般使用者與業務人員使用。內容包含啟動、介面辨識、對話管理、檢索設定、提問、法源查核與常見問題。系統預設在 Windows 10/11 本機執行，不需要 Docker、WSL 或 PostgreSQL。

前端用於查詢與閱讀現行版本法規證據。回答是輔助檢索結果，實際法律判斷仍應以主管機關公告、原始法規與正式解釋為準。

2 使用前準備

啟動前請確認下列項目。

- 已安裝 Python 3.11 以上版本。
- 專案根目錄已建立 .venv 並安裝 ui 選配依賴。
- 已建立 .env，且已執行資料庫初始化。
- data/nfa_fire_law.db 已有法規資料；若尚無資料，應由管理者先完成小量 probe 與增量爬取。

首次安裝可在 PowerShell 執行：

```
python -m venv .venv
Copy-Item .env.example .env
.venv\Scripts\python.exe -m pip install -e ".[ui]"
.venv\Scripts\python.exe -m app.cli init-db
```

3 啟動與停止

3.1 雙擊啟動

在檔案總管中雙擊 scripts\start_streamlit.bat。啟動器會檢查專案的 .venv 與 Streamlit，啟動後自動開啟 http://127.0.0.1:8501。若 8501 已由本專案先前啟動的 Streamlit
占用，啟動器會安全重啟該程序；其他應用程式占用時則不會任意終止。啟動器不會自動安裝套件，也不會爬取法規。

3.2 PowerShell 啟動

```
.venv\Scripts\python.exe -m streamlit run app/streamlit_app.py `
  --server.address 127.0.0.1 `
  --server.port 8501 `
  --browser.gatherUsageStats false
```

頁面上方顯示「台灣消防法規 RAG」後即可開始使用。如果啟動後沒有自動開啟瀏覽器，可手動輸入上述網址。

3.3 停止服務

若以 PowerShell 啟動，回到執行視窗按 Ctrl+C。若以批次檔啟動，關閉對應的 Streamlit 視窗即可。不要為了釋放 8501 連接埠而任意終止其他程式。

4 介面總覽

介面分為左側功能區與右側問答區。左側包含對話列表與檢索設定；右側顯示目前對話、回答、引用與法規證據。



圖 1 前端首頁、對話列表、檢索設定與成功回答區

5 對話管理

- 按「＋新增對話」可建立空白對話。
- 按左側對話標題可切換紀錄，目前對話前會顯示指示符號。
- 按對話右側的「⋯」可編輯標題或刪除對話。
- 對話紀錄保存在本機 SQLite，重新啟動後仍可繼續。

刪除對話會移除該對話及其訊息。若需留存紀錄，請在刪除前確認。

6 檢索設定



圖 2 左側對話列表與檢索設定

設定	作用	使用建議
顯示結果數	設定一般查詢顯示的本機 RAG 證據數，範圍 1 至 20；Web 補充不計入此數量。完整列舉問題可能依章節自動超過此數量	首次使用為 8；調整後立即存到本機 SQLite，重新啟動會恢復最後設定。複雜比較可適度增加
法規篩選	限定只在指定法規中檢索	已知法規名稱時使用；跨法規問題保留「全部法規」
gemma4:e2b	本機速度優先；預設 8,192/2,048 tokens（context/output）	快速查找與較短回答
gemma4:e4b	本機品質優先；預設 16,384/4,096 tokens（context/output）	較完整的整理
gemma4:31b-cloud	雲端品質優先；預設 262,144/8,192 tokens（context/output）	需要 OLLAMA_API_KEY

左側下方會顯示儲存 backend、embedding provider 與向量維度。這些是系統狀態資訊，一般使用者不需要調整。

7 提問與回答

7.1 建議提問方式

在頁面底部的輸入框輸入自然語言問題，再送出查詢。提問時建議同時提供法規名稱、條號、角色或行為，例如：

- 消防法第13條對管理權人有什麼要求？
- 消防設備師與消防設備士的業務範圍有何不同？
- 只查找消防法，說明管理權人的定義。
- /web 消防法第13條最新修正內容

問題開頭的 /web 會強制嘗試官方網頁搜尋，即使本機法規已有高分結果或已完整取回某章節。系統會先移除指令再檢索、搜尋和回答；對話紀錄仍顯示原始提問。只有開頭且獨立的 /web 才是指令，單獨輸入 /web 會提示補上問題。

系統在處理期間會顯示「正在檢索法規並整理回答」。請等待完成，不要連續重複送出相同問題。

啟動頁面、重新整理、送出問題完成回答，或從左側切換既有對話時，畫面會停留在該對話最後一輪的「問題」起點，再往下閱讀回答；不會自動捲到對話最底部。尚未提問的空白對話則維持目前頁面位置。

7.2 閱讀回答與引用

回答中的 [1]、[2] 等編號是可點選引用。按編號後會移到對應的證據卡並展開內容。每張本機證據卡顯示：

- 法規名稱、條號或標籤、章節與版本。
- hybrid、vector 與 lexical 檢索分數。
- 作為回答依據的法規原文。
- 「開啟原始來源」連結。

本機證據卡預設嚴格依 [1] 至 [N]
的引用編號順序顯示，即使同一法規出現多筆，也不會集中卡片而造成跳號；「顯示結果數」計算條文筆數。若另有 Web 補充，會接續編號，例如本機有 8 筆時，Web 證據從 [9] 開始。介面會另外顯示本機與 Web
的編號範圍。回答只需引用實際支持主張的證據，不一定會引用畫面上的每一張卡片。

回答顯示時，所有證據卡（包含第 1
筆）預設收合。點選回答中的引用編號會跳到並展開對應卡片；也可以點選卡片標題自行展開或收合。

當問題明確要求單一法規的「所有 / 全部 / 完整 / 逐條」懲處或罰則條文時，系統會改用結構式章節檢索，不以一般結果數截斷。畫面會顯示「完整列舉模式」、法規 / 章節與覆蓋數，例如 21 / 21；證據卡顯示「結構式章節檢索 · 依條文順序」，不顯示虛構的 hybrid 分數。只有 returned_matches 等於 total_matches 時，系統才標示完整。

對複合包含問題，直接涵蓋明確對象的條文優先，相關母法其次。卡片保留原始 hybrid、vector 與 lexical 分數；分數代表檢索相關度，不代表法律位階。

回答下方的診斷列顯示模型、實際輸出 token 數、有效輸出上限、中文生成狀態及重試次數。正常結束會顯示「生成狀態：已完成」，不直接呈現容易誤解的技術終止碼 stop；有效上限會依剩餘 context
縮小。若回答因長度中斷，系統會精簡重試一次，仍未完成時顯示「達到輸出上限，回答未完整」並明確警告。



圖 3 回答與預設收合的法規證據卡

7.3 官方網頁補充資料

當本機 RAG 沒有結果或最高分數低於設定門檻，且系統已設定 OLLAMA_API_KEY 時，系統可嘗試補充允許清單內的 HTTPS 官方網頁。若在問題開頭輸入 /web
，當次會強制嘗試搜尋，不受本機檢索分數影響。系統會先排除未包含問題明確查詢對象的 Web
結果，再將保留來源接續本機證據編號。介面會標示 Web 筆數、擷取時間與連結。若未設定 key、連線失敗、系統停用或沒有相關來源，介面會說明實際狀態，本機檢索結果仍會保留；強制搜尋不保證取得可引用的網頁資料。

8 查核回答的建議流程

1. 先閱讀回答並確認是否直接回應問題。
2. 按回答中的引用編號，核對對應條文。
3. 確認法規名稱、條號、版本與條文內容符合問題。
4. 如果涉及正式法律判斷，按「開啟原始來源」進一步查證。
5. 證據不足時，加入法規名稱、條號或更明確的行為後重新提問。

9 常見問題與排除

現象	處理方式
瀏覽器無法開啟頁面	確認 Streamlit 視窗仍在執行，再開啟 http://127.0.0.1:8501；若啟動器顯示 8501 被其他程序占用，保留 PID 與錯誤訊息供管理者辨識
顯示端口被佔用	新版啟動器可辨識本專案 Windows venv 的父子程序鏈並安全重啟；若仍拒絕啟動，表示有限父鏈內無法確認是本專案程序，請勿直接終止不相干程式
無法載入法規清單	由管理者確認 .env、DATABASE_URL 與資料庫初始化狀態
檢索沒有結果	改用法規正式名稱、條號或具體關鍵詞；必要時移除過度限定的法規篩選
顯示 LLM 錯誤	法規證據仍可閱讀；請管理者檢查 Ollama 連線、模型名稱、key 與 timeout
顯示回答未完整	查看診斷列的生成狀態、實際輸出 / 上限與重試次數；可縮小問題範圍或減少顯示結果數後重問
web fallback 不可用	確認是否已設定 OLLAMA_API_KEY 與允許的官方網域；本機證據仍可使用
對話標題或紀錄不如預期	重新整理頁面；如果持續發生，請保留錯誤畫面與時間交由管理者檢查

10 使用與資安邊界

- 介面只綁定 127.0.0.1，適合本機使用，未提供登入驗證。
- 不要將介面直接暴露到公開網路或區域網路。
- .env、API key、下載附件與本機資料庫不得加入 Git。
- 不建議在問題中輸入不必要的個人資料、機密或認證資訊。

11 文件維護與版本對齊

本 Markdown 是前端操作說明書的文字來源，docs/assets/frontend-user-guide/ 是畫面來源。前端功能、可見文字、使用流程、預設選項、回答狀態、引用或啟動方式異動時，必須在同一次變更中完成：

1. 更新 docs/FRONTEND_USER_GUIDE.md 的受影響章節。
2. 重新擷取受影響畫面，不沿用已過時截圖。
3. 執行 scripts/build_frontend_user_guide.py --format all，同步產生 Word 與 PDF。
4. 逐頁檢查 Word 轉圖與 PDF 轉圖，確認繁體中文、表格、程式碼、截圖和頁碼清楚易讀。
5. 將 Markdown、截圖、產生器、Word 與 PDF 一併納入同一次 commit。

僅有內部重構且不影響可見行為時，可不重新擷取截圖。實際文件對齊與交付檢查仍以 repository 根目錄 AGENTS.md 第 17 節為準。

日期	版本	異動說明
2026-10-15	2.2	問題開頭加入 /web，可強制嘗試官方網頁搜尋並辨識搜尋狀態
2026-10-13	2.1	顯示結果數調整後立即保存，重新啟動恢復最後設定
2026-09-29	2.0	證據卡改為預設收合，點選回答引用時才展開對應資料

日期	版本	異動說明
2026-09-24	1.9	修正 Windows venv 監聽子程序被誤判為外部程序，導致重複雙擊無法開啟頁面
2026-09-24	1.8	完整列舉問題改用結構式章節檢索，顯示章節範圍與證據覆蓋數
2026-09-22	1.7	問答載入、送出回答及切換對話時，視窗定位到最新問題起點
2026-09-17	1.6	證據卡改為依引用編號順序顯示，避免依法規分組造成跳號
2026-09-16	1.5	診斷列加入實際輸出 token 數，並將技術終止碼改為易懂的中文生成狀態
2026-09-16	1.4	加入模型別 token 上限、截斷重試/警告、證據依法規分組及跨法規來源多樣化說明
2026-09-16	1.3	說明直接條文、母法的證據順序及原始分數意義
2026-09-15	1.2	明確區分本機與 Web 證據數，統一 [N] 編號與排列順序，加入 Web 相關性說明並更新回答證據截圖
2026-09-15	1.1	重新擷取成功回答案例，取代已刪除的失敗案例截圖，並同步更新 Word 與 PDF
2026-09-15	1.0	建立前端專用操作說明書，納入實際畫面、Word、PDF 與後續對齊規範