台灣消防法規 RAG 系統說明書

本說明書說明台灣消防法規 RAG 的系統架構、法規爬取與版本化設計、檢索與回答流程、安裝啟動方式，以及 Streamlit 前端操作。預設目標是 Windows 10/11 的本機 SQLite 執行環境；Docker、WSL、PostgreSQL 與 pgvector 仍保留為選配相容路徑，不是一般使用的必要條件。

文件版本：2026-10-15

適用版本：Phase 2 / v0.2.x

主要資料來源：台灣消防法規公開查詢網站 law.nfa.gov.tw

1. 系統定位與使用邊界

本系統將消防相關公開法規抓取、解析、版本保存、索引與檢索整合成可查詢的本機知識庫。回答介面會保留法規名稱、條號或段落標籤、版本號與來源 URL，讓使用者能回到原始法源核對。

系統是法規檢索與證據整理工具，不取代主管機關正式解釋、行政處分或個案法律意見。若檢索證據不足，回答層應顯示資料不足，不應以模型記憶補齊法律結論。

目前支援的來源分類為：

- A001 通用法令
- A002 預防調查
- A003 危險物品管理

2. 整體架構



2.1 元件與程式位置

元件	程式位置	職責
設定	app/config.py, .env.example	來源網址、資料庫、embedding、LLM、web fallback 與 API 設定
分類與連結探索	app/crawler/categories.py, discovery.py	解析 A001/A002/A003 分類頁，篩選同網域法規 detail URL
HTTP 抓取	app/crawler/fetch.py	TLS 驗證、User-Agent、節流、timeout、有限重試與封鎖停止
來源 URL 正規化	app/crawler/nfa_urls.py	擷取 LSID、建立穩定法規 identity、組合列印版 URL
HTML/PDF 解析	app/parser.py, app/attachments.py	清除頁面雜訊、擷取 metadata、切割條文與附件文字
入庫與版本	app/ingest.py	unchanged/inserted 判斷、保留歷史版本、寫入 embedding 與 FTS5
資料庫	app/db.py, app/models.py	SQLite schema、交易、foreign key、FTS5、embedding bytes
檢索	app/search.py, app/embedding.py, app/rerank.py	lexical + vector hybrid、條號與定義訊號、條件式 rerank
回答	app/answer.py, app/web_search.py	只依證據生成、驗證引用、必要時使用官方網域 web fallback
API/MCP	app/api.py, app/mcp_server.py	HTTP API 與 stdio MCP 工具
前端	app/streamlit_app.py, app/conversations.py	本機問答、對話保存、證據展開與引用定位

2.2 預設執行模式

預設使用單一 SQLite 檔案 data/nfa_fire_law.db，不需要資料庫服務。法規 embedding 預設為 384 維 deterministic character n-gram hash，適合離線 PoC 與無金鑰啟動；它不是訓練好的多語言語意模型。若切換到 OpenAI embedding，必須重新建立所有 chunk 的向量，不能混用不同向量空間。

Ollama/Gemma 是回答層，不是檢索層的必要條件。Ollama 不可用時，仍可使用原始檢索、條文證據與 API；回答層會回報無法產生可驗證引用的狀態。

3. 爬取設計重點

3.1 探索與來源驗證

1. 從分類頁探索法規連結，不預先寫死法規清單。
2. 只接受與 NFA_ALLOWED_HOST 相同的 HTTP/HTTPS host，拒絕外部網址。
3. 排除導覽、列印、新聞、錨點、JavaScript、mailto 與標示為廢止的項目。
4. 以 LSID 作為穩定 identity，忽略 LSID/lsid 大小寫與歷史 ldate 差異。
5. 有 LSID 時優先使用 GNFA/FLAW/PrintFLAWDAT02.aspx 列印版，失敗才回到原始 detail URL；Law.source_url 仍保存人員可辨識的原始法規 URL。

3.2 抓取邊界與禮貌策略

- 單執行緒執行，預設 request 間隔 2 秒，可由 CRAWL_DELAY_SECONDS 調高。
- 啟用作業系統信任憑證鏈的 TLS 驗證，不應為了抓取方便關閉憑證檢查。
- 網路 timeout 預設 20 秒，網路錯誤最多重試 3 次；HTTP 403 或 429 立即停止整批 crawl，不持續加壓。
- 附件以串流下載，預設上限 25 MB、最多 200 頁；超過大小、頁數、非 PDF 或沒有可搜尋文字的附件會記錄原因並跳過。
- 附件只允許同網域來源，支援「附件清單頁 -> 實際 PDF」一層展開，不把任意頁面變成無限爬蟲圖。

3.3 解析、chunk 與 hash

Parser 會清除列印時間、頁尾、導覽與系統提示等動態 chrome，再擷取法規名稱、發布/施行/修正日期、主管機關與法規狀態。正式法規以 第 X 條 切割，並辨識條文段落行首的「第六條第一項所定」等交叉引用，避免誤切成另一條；行政規則或附件則可依 一、二、...、（一） 或阿拉伯數字項次切割。階層式行政規則會把上層節點路徑保存於 heading，使不同章節中重複的 5. 等標籤仍可區分。每個 chunk 保存順序、條號或項次、標題與完整文字。version metadata 另保存 parser_revision，用來判斷既有 chunks 是否需要受控重建，不把 parser 改版誤認為法規內容修正。

content_hash 只對穩定的法規內容與重要 metadata 計算 SHA-256，刻意排除每次抓取都會變動的列印時間。因此同一法規內容未變更時不會重複新增版本，也不會重做 embedding。

3.4 增量版本策略

情況	入庫結果
找不到相同 source_key	建立 Law、版本 1、chunks、embedding 與 FTS5
相同 identity、現行 content_hash 與 parser_revision 均不變	回報 unchanged，保留原 current version
來源未變但現行 parser_revision 落後	回報 reprocess_required，不自動增加法規版本
相同 identity 但內容變更	舊版 is_current=false，新增 version_no、chunks、embedding，更新 FTS5
新內容與某個非現行歷史 hash 相同	仍新增下一個 version_no，保留完整時間序，不重新啟用舊列
單一附件失敗	保存錯誤/跳過原因到 version metadata，不中斷其他法規

一般更新先做小量 probe，再做 --max-laws 小量 crawl，確認結果後才執行完整增量同步。crawl 不會刪除歷史版本；若來源內容回復成先前文字，系統會建立新的時間序版本，避免 current 指標停留在錯誤版本。例行測試不得對真實 local database 做 destructive setup，也不應在未確認網站可達性時直接完整 crawl。

4. 資料模型與可追溯性

資料表	主要內容
laws	穩定 source_key、法規名稱、分類、原始來源 URL
law_versions	版本號、content hash、完整 raw text、metadata、current 狀態、抓取時間
law_chunks	version 關聯、seq、條號、標題、chunk 內容、float32 embedding
law_chunks_fts	SQLite FTS5 lexical index，只重建現行版本，並保存 chunk/law/version 對照欄位
conversations	Streamlit 本機對話標題與時間
conversation_messages	使用者問題、助手輸出與完整 response JSON
ui_preferences	本機 Streamlit 共用設定；display_result_count 保存最後選擇的結果數

所有回答面向的結果至少應帶出：法規名稱、條號/段落標籤、版本號、原始來源 URL。version_no 是系統保留版本的序號；真正法律效力仍應回到來源頁面的發布、施行或修正日期核對。

5. 檢索與回答流程

5.1 Hybrid search

SQLite 檢索先以 FTS5 取得候選，再以 NumPy 計算 embedding cosine similarity，並融合文字重疊、法規名稱 routing、明確條號、「本法所稱 X」定義句型及包含問題的精確對象訊號。中文查詢使用 character n-gram，避免只依賴空格分詞。預設 hash embedding 的 vector weight 為 0.30，讓可解釋的法律詞彙訊號優先。

/v1/search 與 MCP search_fire_law 提供原始檢索排序；/v1/ask、MCP ask_fire_law 與 Streamlit 問答會對「包含哪些、是否包含某對象」或「某主題相關規定」等跨法規問題取得 bounded candidate pool，保留不同法規來源、直接主管辦法及最相關母法。初步選擇以不同法規優先，同一法規最多兩筆，再依原始相關度補滿；回答證據先列直接主管辦法或涵蓋明確對象的條文，再列相關母法。此順序不改寫原始 hybrid、vector 或 lexical 分數，也不把法律位階當作檢索分數。角色比較、權限或業務範圍問題則取得較大候選集，再由設定的 Gemma 進行條件式重排。重排失敗會安全回退原始排序。

完整列舉與相關性排序是不同需求。當問題明確指定一個法規、包含「所有 / 全部 / 完整 / 逐條」意圖，且主題可對應「懲處 / 處罰 / 裁罰 / 罰則」時，回答入口會精確限制法規名稱，依現行版本的「罰則」章節與 LawChunk.seq 取回全部實質條文，排除刪除條文。此結構式模式不套用一般 top_k 截斷，也不以 synthetic 分數取代原始 hybrid 分數；API、MCP 與前端均回報檢索模式、章節範圍、總筆數、回傳筆數及完整狀態。一般查詢仍維持原本的 hybrid / 多樣化 / 條件式 rerank 流程。

5.2 證據回答與 web fallback

回答 prompt 只會收到現行本機檢索片段，並要求每個重要法律主張附 [1]、[2] 等證據編號。系統會拒絕不存在或完全缺少的引用；此時保留原始條文給使用者核對，不把未驗證文字當作可靠法律答案。

同一法規、版本與來源 URL 的多筆章節證據會在 prompt 中保留第一筆完整來源，後續以引用第一筆來源的方式壓縮重複 provenance；條文原文、條號、章節與引用編號仍完整保留。完整結構式結果不會因 placeholder 分數偏低而觸發 web fallback。

回答長度依前端選定模型套用獨立 profile，而不是共用 512 tokens：gemma4:e2b 預設 context/output 為 8192/2048、gemma4:e4b 為 16384/4096、gemma4:31b-cloud 為 262144/8192。effective output 取「設定輸出上限」與「context 扣除估計 prompt 及安全餘量」的較小值；本機模型還會以快取的 /api/show 架構 context 作上限。系統保存 done_reason、prompt/eval token count 與重試次數；長度截斷或疑似半句會精簡重試一次，仍未完成則回傳 answer_status=incomplete。

當本機無命中、最高 hybrid 分數低於 WEB_SEARCH_MIN_HYBRID_SCORE，或模型明確表示證據不足時，可選擇啟用 Ollama hosted web search。Web 結果只接受 .env 的 HTTPS 官方網域清單；若問題明確詢問是否包含某對象，還必須在標題或擷取內容中涵蓋該對象，避免泛稱「相關法條」但未支持問題的頁面進入回答證據。保留結果會標示為「官方網頁補充資料」與擷取時間，不能默默覆蓋或合併本機現行法規。

問答入口支援在問題開頭輸入 /web ，或由 API/MCP 指定 web_mode=force，不受本機分數或完整章節模式影響而嘗試一次官方網頁搜尋。程式在檢索前移除指令，避免 /web 混入檢索、Web 查詢及模型問題；一般問題使用 web_mode=auto。強制搜尋仍須符合 WEB_SEARCH_ENABLED、Ollama API key、HTTPS 官方網域白名單與相關性過濾，並不保證有可引用的結果。回應以 web_search_mode 與 web_search_status 區分使用者意圖與實際結果；無結果或服務不可用時仍保留本機證據與回答。

6. 安裝與啟動

以下以 Windows PowerShell 為主。指令應在 repository 根目錄執行。

6.1 前置條件

- Windows 10/11
- Python 3.11 以上，建議使用 repository 內的 .venv
- 可連線來源網站的環境，只有 probe/crawl 需要外部網路
- 不需要 Docker、WSL、PostgreSQL 或系統管理員權限

6.2 建立環境與安裝

```
python --version
python -m venv .venv
Copy-Item .env.example .env
.venv\Scripts\python.exe -m pip install --upgrade pip
.venv\Scripts\python.exe -m pip install -e ".[dev,ui]"
```

.env 是本機設定檔，不可提交 Git。初次使用可先維持預設的 SQLite、hash embedding；若要使用 OpenAI embedding 或 Ollama Cloud，才填入對應金鑰。API 與 UI 預設應綁定 loopback 使用，公開部署前必須先補認證與反向代理控管。

6.3 初始化資料庫與確認 API

```
.venv\Scripts\python.exe -m app.cli init-db
.venv\Scripts\python.exe -m uvicorn app.api:app --host 127.0.0.1 --port 8000
```

另開一個 PowerShell 視窗確認：

```
Invoke-RestMethod http://127.0.0.1:8000/health
Start-Process http://127.0.0.1:8000/docs
```

API 要長駐執行時，請保留該視窗；停止可按 Ctrl+C。/v1/admin/crawl 目前沒有登入認證，只適合本機或受控內網使用。

6.4 首次 probe 與增量爬取

```
.venv\Scripts\python.exe -m app.cli probe --max-laws 3
.venv\Scripts\python.exe -m app.cli crawl --categories A001,A002,A003 --max-laws 3
```

小量結果正常後，再執行：

```
.venv\Scripts\python.exe -m app.cli crawl --categories A001,A002,A003
```

單一分類也可使用：

```
.venv\Scripts\python.exe -m app.cli crawl --max-laws 3
```

probe 不需資料庫與 embedding，會回報 LSID、retrieved URL、chunk 數、首末條號、metadata、content hash 與附件 URL，適合先確認站台格式。crawl 是增量操作，未變更法規不會建立新版本。

6.5 Parser 升版後重建現行 chunks

parser/chunk 規則升版後，先執行 dry-run；此步驟不連網也不寫入資料：

```
.venv\Scripts\python.exe -m app.cli reprocess-current
```

輸出會列出法規 ID、版本、舊/新 parser revision、chunk 數及 hash 是否變動。確認清單後，先複製備份 data\nfa_fire_law.db，再套用：

```
.venv\Scripts\python.exe -m app.cli reprocess-current --apply
```

如只處理特定法規，可重複使用 --law-id。套用作業在單一資料庫交易中，僅重建現行版本的 chunks、embedding、metadata/hash 與 current-only FTS；不改 version_no，也不刪除或重新啟用歷史版本。若 embedding provider 已改變，不應把本命令當成跨 provider migration，仍須先確認整庫向量相容性。

6.6 啟動 Streamlit 前端

方法一：雙擊 scripts\start_streamlit.bat。啟動器會檢查 .venv 與 Streamlit，確認 8501 port，僅停止本 repository 自己留下的舊 Streamlit process，等待 health endpoint 後開啟瀏覽器。Windows venv 可能讓監聽子程序顯示為系統 Python，因此辨識時會向上檢查最多四層父程序；只有命令列同時包含 repository 絕對路徑與 streamlit 才會終止該程序樹，其他占用者仍維持 fail-closed。

方法二：PowerShell 手動啟動：

```
.venv\Scripts\python.exe -m streamlit run app/streamlit_app.py `
  --server.headless true `
  --server.address 127.0.0.1 `
  --server.port 8501 `
  --browser.gatherUsageStats false
```

開啟 http://127.0.0.1:8501。若只使用 UI，仍建議先完成 init-db 與至少一次 crawl；UI 啟動時會自動初始化 schema，但不會自動爬取法規。

6.7 API、MCP 與評估入口

常用 API：

```
Invoke-RestMethod "http://127.0.0.1:8000/v1/laws"
Invoke-RestMethod "http://127.0.0.1:8000/v1/search?q=防火管理人有哪些責任&top_k=8"
Invoke-RestMethod "http://127.0.0.1:8000/v1/article?law_title=消防法&article=第13條"
```

MCP 使用 stdio；在 MCP client 設定中以 repository 內的 Python 啟動：

```
{
  "mcpServers": {
    "nfa-fire-law": {
```

```
      "command": "C:\\path\\to\\nfa-fire-law-rag\\.venv\\Scripts\\python.exe",
      "args": ["-m", "app.mcp_server"],
      "cwd": "C:\\path\\to\\nfa-fire-law-rag"
    }
  }
}
```

提供的 MCP 工具為
search_fire_law、ask_fire_law、get_fire_law_article、list_fire_laws、list_law_versions。檢索 smoke test：

/v1/ask 與 MCP ask_fire_law 的 web_mode 可為 auto（預設）或 force；兩者也接受問題開頭的 /web 指令。回應的 query 為移除指令後的問題，並回傳 web_search_mode、web_search_status。單獨輸入 /web 會拒絕為空問題；一般 /v1/search 與 MCP search_fire_law 不解析此問答指令。

```
.venv\Scripts\python.exe -m app.cli eval --path eval/phase2_queries.json --top-k 8
```

7. Streamlit 前端操作說明

7.1 側邊欄

- 對話列表：選擇既有對話；對話會保存於本機 SQLite，重啟後仍可查看。
- 新增對話：建立空白對話。
- ... 選單：修改對話標題或刪除對話。刪除會移除該對話及其訊息，不會刪除法規資料。
- 顯示結果數：控制一般查詢顯示 1 至 20 筆本機 RAG 證據；Web 補充不計入此數量。首次使用為 8，調整時立即存入設定的 SQLite 資料庫 ui_preferences，重新啟動後恢復最後設定。此值是本機介面的共用設定；完整列舉問題可依章節自動超過此數量。
- 法規篩選：選擇全部法規或限定某一法規名稱。
- 回答模型：gemma4:e2b 偏速度、gemma4:e4b 偏完整、gemma4:31b-cloud 偏雲端品質；這是當次查詢選擇，不會改寫全域設定，且會一併選取相應的 context/output profile。

7.2 問答與證據

在底部輸入自然語言問題，例如「消防法第13條對管理權人有什麼要求？」。回答區會依序顯示：模型回答或資料不足提示、本機檢索摘要、現行法規證據卡片，以及必要時的 web 補充來源。啟動、重新整理、完成回答或切換左側對話時，前端會將視窗定位在該對話最新一輪的問題起點，而不是自動捲到最下方；空白對話沒有定位目標時則不強制捲動。

若要指定當次查詢嘗試官方網頁搜尋，在問題最前方輸入 /web ，例如 /web 消防法第13條最新修正內容。畫面保存並顯示原始提問，檢索及回答使用去除指令後的問題；搜尋成功、無結果、缺少金鑰、連線失敗或系統停用時，提示會依強制模式說明實際狀態，不會把強制查詢誤稱為「RAG 證據不足」。

本機證據卡片嚴格依 [1] 至 [N] 的引用編號順序顯示，top_k 計算一般查詢的個別條文；每張 hybrid 卡片保留獨立 [N]、法規名稱、條號、標題、版本與 hybrid/vector/lexical 分數，再接續 Web 證據。完整列舉時，畫面改顯示結構式章節檢索、章節範圍與例如 21 / 21 的覆蓋數，並按法規原始條文順序顯示。畫面另列本機與 Web 的編號範圍。所有證據卡在回答顯示時預設收合；點擊卡片標題可展開原文，點擊回答中的 [N] 引用會跳到並展開對應證據。回答下方顯示模型、實際輸出 token 數、當次有效輸出上限、中文生成狀態及重試次數；原始 done_reason 仍保留在回應資料中。分數是排序訊號，不是法律效力。

若看到「RAG 證據不足」提示，應優先改用更具體的法規名稱、條號、角色或動作詞，再檢查原始來源。web fallback 若無金鑰、無結果或連線失敗，介面仍會顯示本機檢索結果與狀態，不會假裝已完成外部查詢。

7.3 建議提問方式

- 具體指定法規名稱與條號：消防法第13條管理權人義務
- 問定義時指出名詞：消防法所稱管理權人是什麼
- 問責任時指出動作：防火管理人應負哪些責任
- 比較不同角色時說明比較面向：管理權人與防火管理人的設置及責任有何不同

8. 設定與故障排除

現象	優先檢查
ModuleNotFoundError	是否使用 .venv\Scripts\python.exe，以及是否已安裝 -e ".[dev,ui]"
UI 顯示沒有資料	確認 DATABASE_URL、執行 init-db，再做 probe/crawl
來源站 DNS/連線失敗	先只做 probe --max-laws 3；確認網路政策與 NFA_ALLOWED_HOST，不要直接完整 crawl
HTTP 403/429	依程式停止，稍後再試並提高 CRAWL_DELAY_SECONDS，不要增加併發或重試壓力
Ollama 回答失敗	先使用 /v1/search 或查看證據；確認 Ollama URL、模型與金鑰。檢索本身不依賴 Ollama
回答顯示未完整	查看生成狀態、實際輸出 / 上限與重試次數；縮小問題或減少結果數。系統不會把長度截斷標成正常答案
Cloud/web fallback 不可用	確認 OLLAMA_API_KEY、允許網域與 HTTPS；未設定時屬預期的 unavailable 狀態
Streamlit port 被占用	重新執行新版啟動器；它會辨識本 repository 的 Windows venv 父子程序鏈並安全重啟。若仍顯示不相關 PID，表示無法安全確認擁有者，應人工核對後關閉或修改 port，不要任意終止 process
切換 embedding provider	使用新的 DATABASE_URL 或受控 re-embedding 流程，先備份 SQLite，避免混用向量
crawl 顯示 reprocess_required	先執行 reprocess-current dry-run，備份 SQLite 後再以 --apply 重建現行衍生資料

9. 文件維護與變更紀錄

本手冊負責說明系統如何使用；後續程式異動的文件責任、對齊矩陣與交付檢查表，統一依 repository 根目錄的 [AGENTS.md](../AGENTS.md) 第 17 節執行。採影響範圍驅動的方式維護文件：只有影響操作、資料契約、來源規則、執行方式、資安邊界或驗證方式的變更，才需要同步受影響文件。PDF 是本手冊的列印與分享版本，由 scripts/build_system_manual_pdf.py 產生，不直接手工編輯。

日期	內容
2026-10-15	問答支援 /web 與 web_mode=force，顯示強制搜尋結果及不可用原因
2026-10-13	前端顯示結果數存入 SQLite，重新啟動後恢復最後設定
2026-09-29	證據卡顯示時預設收合，點擊回答引用後展開目標卡片
2026-09-24	修正 Windows venv 啟動器辨識；加入完整列舉罰則檢索與覆蓋 metadata
2026-09-22	問答載入、回答完成及切換對話時，視窗定位到最新問題起點
2026-09-17	證據卡改為依引用編號順序顯示，避免同法規集中顯示造成跳號
2026-09-16	回答診斷列加入實際輸出 token 數，並將原始終止碼轉為易懂的中文生成狀態

日期	內容
2026-09-16	加入 parser revision、條文交叉引用防誤切、歷史 hash 回復保護，以及 dry-run 優先的 reprocess-current 工作流程
2026-09-16	加入跨法規主題覆蓋、證據來源多樣化、階層項次、模型別 token profile 與截斷偵測/重試
2026-09-16	統一產品名稱為「台灣消防法規 RAG」，來源說明改用中性名稱
2026-09-16	複合包含問題先列直接對象條文，再列相關母法，並保留原始檢索分數
2026-09-15	加入複合包含問題的證據覆蓋、Web 明確對象過濾，以及統一的本機 / Web 引用編號呈現
2026-09-14	建立系統說明書與 Markdown 產生的 PDF，納入架構、爬取、啟動、Streamlit 操作及 AGENTS.md 文件對齊規範